

DailyBox 마케팅 전략 분석

0. 분석 개요

1) 지난 분기 쿠폰 캠페인의 효과, (2) 채널별 고객 가치, (3) 매출을 끌어올리는 실제 레버, (4) 다음 캠페인 타겟 세그먼트를 데이터로 검증하는 것을 목표로 한다. 분석 대상은 고객 6,000명의 한 달치 스냅샷 데이터 (marketing_customers.csv)이며, 결측치는 없다.

Part 1. 고객 이해 (EDA)

1. 데이터 구조

전체 고객 수는 6,000명, 변수는 13개이며 결측치는 존재하지 않는다. 주요 수치형 변수의 범위는 다음과 같다.

변수	평균	최소	최대
age (나이)	40.3세	18세	78세
monthly_visits (월 방문)	8.2회	1회	34회
monthly_spend (월 매출)	32,275원	8,260원	288,440원

고객 규모는 6,000명으로 충분히 크고, monthly_spend의 최대값이 평균의 약 9배에 달해 소수 고객이 매출을 크게 끌어올리는 구조로 보인다.

2. 매출 분포와 로그변환

monthly_spend의 왜도(skewness)는 2.55로, 오른쪽으로 크게 치우친(right-skewed) 분포를 보인다. 이는 대다수 고객의 지출은 20~40 구간에 몰려 있지만, 소수의 고가치 고객이 훨씬 높은 지출을 하면서 분포의 오른쪽 꼬리를 길게 만들기 때문이다. log1p 변환 후 왜도는 0.38로 크게 완화되어, 이후 정규성이 요구되는 분석(회귀 잔차 진단 등)에서 로그변환이 유용함을 확인할 수 있다.

3. 채널·등급별 매출

signup_channel별 monthly_spend 평균은 Influencer(42.9) > Referral(36.7) > Organic Search(30.5) > Social Ads(25.9) 순으로 나타났다. membership_tier별로는 Gold(36.5) > Silver(32.9) > Basic(30.9) 순이다. Boxplot 상에서도 Influencer와 Gold 등급의 중앙값과 상자 범위가 다른 그룹보다 위쪽에 위치해, 고가치 고객이 상대적으로 많이 분포함을 시각적으로 확인할 수 있다.

Part 2. 가정 확인

4. 1 종/2 종 오류 (개념)

귀무가설 H_0 : '쿠폰 캠페인은 매출에 효과가 없다'를 기준으로,

- 1 종 오류(α): 실제로는 캠페인 효과가 없는데 '효과가 있다'고 잘못 판단하는 경우 → 효과 없는 캠페인에 계속 예산을 투입하게 되어 마케팅 예산 낭비로 이어진다.
- 2 종 오류(β): 실제로는 캠페인 효과가 있는데 '효과가 없다'고 잘못 판단하는 경우 → 실제로는 매출을 늘릴 수 있는 캠페인을 중단하게 되어 기회 손실(놓친 매출)이 발생한다.

5. 정규성 검정 (Shapiro-Wilk)

H_0 : Organic Search 채널의 monthly_spend는 정규분포를 따른다 / H_1 : 정규분포를 따르지 않는다.

원본 데이터($n=500$ 샘플)의 Shapiro-Wilk 검정 결과 $W=0.853$, $p<0.001$ 로 유의수준 0.05 하에서 H_0 을 기각한다(정규성 위배). $\log_{10}$ 변환 후에는 $W=0.987$, $p=0.0002$ 로 여전히 $p<0.05$ 이지만 W 값이 1에 훨씬 가까워져, 완전한 정규성은 아니어도 정규분포에 근사한 형태로 크게 개선되었음을 알 수 있다.

6. 등분산성 검정 (Levene)

4개 채널 간 monthly_spend 분산에 대한 Levene 검정 결과 $F=69.36$, $p<0.001$ 로 유의수준 0.05 하에서 등분산 가정이 기각된다. 즉 채널 간 매출의 분산이 서로 다르다는 의미이며, 이는 이후 One-way ANOVA의 등분산 가정이 완전히 충족되지 않은 상태에서 분석이 진행됨을 시사한다(다만 표본 크기가 크고 그룹별 표본수가 비슷해 ANOVA는 어느 정도 강건하다고 알려져 있다).

Part 3. 집단 비교 검정

7. 쿠폰 캠페인 효과 — Welch's t-test

H_0 : control군과 treatment군의 monthly_spend 평균은 같다 ($\mu_{\text{control}} = \mu_{\text{treatment}}$) / H_1 : 다르다.

Levene 검정 결과 $p<0.001$ 로 등분산 가정이 기각되어 Welch's t-test를 사용하였다. control 평균은 29.71, treatment 평균은 34.80이며, $t=-11.88$, $p<0.001$ 로 유의수준 0.05 하에서 H_0 을 기각한다. 즉 쿠폰을 받은 고객군의 매출이 통계적으로 유의하게 높다.

결론: 캠페인은 실제로 매출 증가 효과가 있는 것으로 확인되므로, 다음 분기에도 캠페인을 지속하는 것이 타당하다.

8. 채널 비교 — One-way ANOVA + Tukey HSD

H0: 4개 채널의 monthly_spend 평균은 모두 같다 / H1: 적어도 한 채널은 다르다.

One-way ANOVA 결과 $F=276.85$, $p<0.001$ 로 H0을 기각한다. Tukey HSD 사후검정 결과 6개 채널 쌍 모두 통계적으로 유의한 차이를 보였다(reject=True).

채널 쌍	평균차	유의 여부
Influencer - Organic Search	-12.36	유의
Influencer - Referral	-6.18	유의
Influencer - Social Ads	-17.02	유의
Organic Search - Referral	+6.18	유의
Organic Search - Social Ads	-4.66	유의
Referral - Social Ads	-10.84	유의

결론: Influencer 채널이 통계적으로 가장 고가치 고객을 데려오며, Social Ads가 가장 저가치 고객을 데려온다. Boxplot과 종합할 때 채널별 예산 배분에서 Influencer·Referral 비중을 높이는 것을 고려할 수 있다.

9. 교호작용 — Two-way ANOVA (심화)

signup_channel과 campaign_group을 독립변수로 한 Two-way ANOVA 결과, 채널 주효과($p<0.001$), 캠페인 주효과($p<0.001$)에 더해 채널×캠페인 교호작용 또한 유의하였다($p<0.001$). 이는 캠페인의 효과 크기가 채널마다 동일하지 않다는 것을 의미하며, 캠페인 예산을 모든 채널에 균등하게 배분하기보다 효과가 큰 채널에 집중하는 전략이 더 효율적일 수 있음을 시사한다.

Part 4. 회귀분석

10. 단순선형회귀 & 다중회귀

단순회귀(monthly_visits → monthly_spend): 방문 1회 증가 시 매출이 약 0.93 증가하며, $R^2=0.054$ 로 설명력은 낮다.

다중회귀(monthly_visits + avg_discount_rate + online_ad_cost + signup_channel + gender): Adjusted R^2 가 0.217로 단순회귀보다 크게 개선되었다. 세 수치형 변수 모두 통계적으로 유의했다.

변수	계수	해석
monthly_visits	+0.92	방문 1회당 매출 약 0.92 증가
avg_discount_rate	+11.42	할인율이 높을수록 매출도 높게 관측됨

online_ad_cost	+0.37	광고비 1단위당 매출 약 0.37 증가
----------------	-------	-----------------------

전략적으로는 monthly_visits(재방문 유도)와 online_ad_cost가 매출에 안정적으로 기여하는 레버로 보인다. 다만 avg_discount_rate의 양(+)의 계수를 '할인을 늘리면 매출이 는다'는 인과로 바로 해석하는 것은 주의가 필요하다 — 이미 지출 여력이 큰 고객에게 높은 할인이 몰려 있을 가능성(역인과·선택편향)이 있어, 단순 상관을 인과로 단정하기는 어렵다.

11. 다중공선성 / VIF

online_ad_cost, offline_ad_cost, total_ad_cost 세 변수를 모두 넣어 VIF를 계산한 결과 세 변수 모두 VIF가 발산(inf)하였다. 이는 total_ad_cost가 online_ad_cost와 offline_ad_cost의 정확한 선형결합(total = online + offline)으로 정의되어 완전한 다중공선성이 발생하기 때문이다. total_ad_cost를 제거하면 online_ad_cost, offline_ad_cost의 VIF는 각각 약 1.0으로 정상 수준으로 낮아진다. 해결책은 세 변수 중 하나(특히 정의상 종속된 total_ad_cost)를 회귀식에서 제외하는 것이다.

12. 잔차 진단

원본 monthly_spend를 종속변수로 한 다중회귀 모형의 잔차는 왜도 2.41로 정규성 가정이 크게 위배되어 있다. 종속변수를 log1p(monthly_spend)로 바꾼 모형에서는 잔차 왜도가 0.32로 크게 개선되었으며, Q-Q plot 상에서도 정규분포 기준선에 더 가깝게 나타난다. 등분산성(잔차 vs 예측값 산점도) 역시 로그모형에서 원본 모형 대비 깔때기 모양(이분산)이 완화된 형태를 보인다.

Part 5. 타겟팅 (로지스틱 회귀)

13~14. 로지스틱 회귀 & 오즈비 해석

responded를 종속변수로 한 로지스틱 회귀 결과, age·monthly_visits·campaign_group·membership_tier·signup_channel 모두 통계적으로 유의하였다($p < 0.001$). 주요 변수의 오즈비는 다음과 같다.

변수	오즈비	해석
campaign_group = treatment	2.43	쿠폰을 받은 고객은 받지 않은 고객보다 반응 오즈가 2.43배
membership_tier = Gold (vs Basic)	2.02	Gold 등급은 Basic 대비 반응 오즈가 2.02배
membership_tier = Silver (vs Basic)	1.41	Silver 등급은 Basic 대비 반응 오즈가 1.41배

실제 반응률로 보면 control군 16.1% vs treatment군 31.2%, Basic 18.9% vs Gold 37.6%로 로지스틱 회귀 결과와 방향이 일치한다. 결론적으로 다음 캠페인은 Gold·Silver 등급이면서 방문 빈도가 높은 고객군에 쿠폰을 집중 발송할 때 반응률이 가장 높을 것으로 기대된다.

종합 결론 — CMO 보고용 마케팅 전략

1. 캠페인 지속 여부

Welch's t-test(7번)와 로지스틱 회귀(13~14번) 모두 쿠폰 캠페인이 매출과 반응률을 통계적으로 유의하게 높인다는 결과를 보였다. 다음 분기에도 캠페인을 지속하는 것을 권장한다.

2. 채널 예산 배분

Boxplot(3번)과 Tukey HSD(8번) 결과를 종합하면 Influencer·Referral 채널이 통계적으로 유의하게 고가치 고객을 데려온다. Social Ads의 예산 비중을 줄이고 Influencer·Referral 채널에 재배분하는 것을 제안한다.

3. 매출 레버

다중회귀(10번) 결과 monthly_visits와 online_ad_cost가 매출에 안정적으로 기여하는 레버로 확인된다. 재방문을 유도하는 리텐션 시책(알림, 리워드 등)에 투자하는 것이 할인율 확대보다 더 근거가 명확한 전략이다.

4. 타겟팅

오즈비 분석(14번) 결과 Gold·Silver 등급 고객에게 쿠폰을 집중할 때 반응률이 가장 높다. 다음 캠페인은 전체 고객 대상 일괄 발송 대신 상위 등급 고객군에 예산을 집중하는 타겟팅 방식을 제안한다.

5. 분석의 한계

- 한 달치 스냅샷 데이터이므로 계절성이나 장기 트렌드는 반영되지 않았다.
- total_ad_cost 는 online/offline 의 정의상 합으로, 다중공선성에 유의해 해석해야 한다(11 번).
- campaign_group 은 무작위 배정이므로 인과 해석이 비교적 안전하지만, avg_discount_rate 등 다른 변수들과의 관계는 관찰 데이터 기반 상관관계로, 인과관계로 단정할 수 없다.
- Shapiro-Wilk 검정 결과 log1p 변환 후에도 완전한 정규성은 만족되지 않아, 일부 검정 결과는 참고용으로 해석할 필요가 있다.