

1. 분석 목적

이번 과제에서는 신용카드 거래 데이터로 사기 거래를 분류하는 모델을 만들었다. 원본 데이터는 정상 거래가 대부분이고 사기 거래는 매우 적기 때문에, 일반적인 정확도만으로는 모델의 성능을 제대로 판단하기 어렵다. 따라서 데이터 불균형을 처리하고 Recall, F1-score, PR-AUC 를 중심으로 모델을 평가하였다.

2. 데이터 확인

데이터는 총 284,807 개의 거래와 31 개의 변수로 구성되어 있다. Class 가 0 이면 정상 거래, 1 이면 사기 거래를 의미한다. 결측치는 없었고 중복 행은 1,081 개가 확인되었다. 과제 명세에 중복 제거 지시가 없었기 때문에 이번 분석에서는 그대로 사용하였다.

구분	거래 수	비율
정상 거래(Class=0)	284,315	99.827%
사기 거래(Class=1)	492	0.173%

사기 거래의 비율은 약 0.173%에 불과하다. 만약 모델이 모든 거래를 정상으로 예측해도 정확도는 약 99.83%가 된다. 따라서 이 문제에서는 정확도보다 실제 사기를 얼마나 찾아냈는지 보여주는 Recall 과 Precision, F1-score 를 확인하는 것이 중요하다.

3. 데이터 샘플링과 전처리

과제 명세에 따라 사기 거래 492 건은 모두 유지하고, 정상 거래에서는 random_state=42 로 10,000 건을 무작위 추출하였다. 두 데이터를 합친 분석용 데이터는 총 10,492 건이며, 샘플링 후 사기 거래 비율은 약 4.69%이다.

Amount 변수는 다른 변수에 비해 값의 범위가 크기 때문에 StandardScaler 를 사용해 표준화하고 Amount_Scaled 로 대체하였다. 원본 Amount 변수는 제거한 뒤 Class 를 y 로, 나머지 변수를 X 로 분리하였다.

4. 학습 데이터와 테스트 데이터 분할

`train_test_split` 을 사용해 학습 데이터와 테스트 데이터를 8:2 로 나누었다. `random_state` 는 42 로 설정했고 `stratify=y` 를 적용해 두 데이터셋의 클래스 비율이 비슷하게 유지되도록 하였다. 테스트 데이터는 최종 성능 평가에만 사용하였다.

5. SMOTE 적용

사기 거래가 적으면 모델이 정상 거래 위주로 학습될 수 있다. 이를 완화하기 위해 학습 데이터에만 SMOTE 를 적용하였다. SMOTE 는 소수 클래스에 속한 데이터의 이웃 관계를 이용해 새로운 합성 데이터를 생성한다. 테스트 데이터에는 적용하지 않았는데, 테스트 데이터까지 변형하면 실제보다 성능이 높게 측정될 수 있기 때문이다.

6. 모델과 임계값 선택

최종 모델로 `ExtraTreesClassifier` 를 사용하였다. Extra Trees 는 여러 개의 결정트리를 결합하는 앙상블 모델이며, 비선형적인 패턴을 학습할 수 있다는 점을 고려해 선택하였다. `n_estimators` 는 400 으로 설정하였다.

예측 임계값은 기본값 0.5 를 바로 사용하지 않고 학습 데이터 내부의 검증 데이터에서 조정하였다. Recall 이 0.80 이상이고 F1-score 가 0.88 이상인 후보 중 F1-score 가 가장 높은 임계값을 선택했으며, 최종 임계값은 0.37 이었다. 테스트 데이터로 임계값을 선택하지 않아 테스트 데이터에 대한 과적합을 피하고자 하였다.

7. 최종 결과

클래스	Precision	Recall	F1-score	Support
정상 거래(0)	0.9935	0.9965	0.9950	2,001
사기 거래(1)	0.9239	0.8673	0.8947	98

테스트 데이터에서 PR-AUC 는 0.9305 였다. 사기 거래 98 건 중 85 건을 사기로 탐지했고 13 건을 놓쳤다. 정상 거래 2,001 건 중에서는 7 건을 사기로 잘못 예측하였다.

평가 목표	결과	달성 여부
Recall $\geq$ 0.80 (Class 0, 1)	0.9965 / 0.8673	달성
F1 $\geq$ 0.88 (Class 0, 1)	0.9950 / 0.8947	달성
PR-AUC $\geq$ 0.90	0.9305	달성

과제에서 제시한 Recall, F1-score, PR-AUC 목표를 모두 달성하였다. 임계값을 0.5 에서 0.37 로 낮추면서 사기 거래를 조금 더 적극적으로 탐지하도록 조정했지만, 임계값이 낮아질수록 정상 거래를 사기로 잘못 분류할 가능성도 커진다는 점을 함께 고려해야 한다.

8. 한계와 추가 개선 방법

- Stratified K-fold 교차검증을 사용하면 특정 검증셋에 의존하지 않고 임계값과 하이퍼파라미터를 더 안정적으로 선택할 수 있다.
- `n_estimators`, `max_depth`, `min_samples_leaf` 등의 하이퍼파라미터를 탐색할 수 있다.
- Borderline-SMOTE, SMOTE-Tomek 또는 `class_weight` 같은 다른 불균형 처리 방법과 비교할 수 있다.
- XGBoost 나 LightGBM 과 같은 부스팅 모델을 추가로 비교할 수 있다.
- 실제 서비스에서는 사기를 놓쳤을 때의 비용과 정상 거래를 차단했을 때의 비용을 반영해 임계값을 정해야 한다.

9. 결론

이번 분석에서는 정상 거래 샘플링, Amount 표준화, 계층적 데이터 분할, SMOTE, Extra Trees 모델 학습, 임계값 조정까지 불균형 분류 문제의 전체 과정을 수행하였다. 최종적으로 사기 클래스 Recall 0.8673, F1-score 0.8947, PR-AUC 0.9305 를 얻어 과제에서 제시한 목표를 만족하였다.